

Image Captioning Progressivo: dall'Encoder ViT a CLIP su Flickr8k e Flickr30k

Emiliano Moriconi, Guido Paluzzi
Roberto Sacchetti, Marco Mazzillo

Bachelor's Degree Programme in Applied Computer Science and Artificial Intelligence (ACSAI)
Course: AI-LAB – Computer Vision, Signal Processing, and Natural Language Processing
Department of Computer Science, Sapienza University of Rome
Matricola: 1944917, 2053090, 2014782, 2082152

moriconi.1944917@studenti.uniroma1.it
paluzzi.2053090@studenti.uniroma1.it
sacchetti.2014782@studenti.uniroma1.it
mazzillo.2082152@studenti.uniroma1.it

Sommario

Questo lavoro presenta uno studio ablativo e progressivo sull'Image Captioning utilizzando un'architettura modulare encoder-decoder (ViT/CLIP + GPT-2 small). Partendo da una baseline con BLEU-4 di 8.31 su Flickr8k, quantifichiamo l'impatto isolato di tre variabili: introduzione di best practice di training, scale-up del dataset (tramite Flickr30k) e upgrade dell'encoder a CLIP ViT-L/14.

Il sistema ottimizzato fa registrare un incremento prestazionale del +209%, raggiungendo un BLEU-4 finale di 25.65. L'analisi evidenzia che l'aumento dei dati è il fattore più determinante (+94%), seguito dall'adozione di CLIP-L (+35%). Quest'ultimo, grazie a un pre-addestramento allineato al linguaggio naturale, dimostra una netta superiorità nella generalizzazione cross-distribution rispetto a modelli puramente visivi.

Keywords: Image Captioning, Vision Transformer, GPT-2, CLIP, Studio Ablativo.

1 Introduzione

L'Image Captioning è il compito di generare automaticamente una descrizione testuale a partire da un'immagine. Si tratta di un problema al confine tra computer vision e natural language processing, che richiede al sistema di comprendere il contenuto visivo di una scena e di tradurlo in linguaggio naturale fluente e semanticamente corretto.

Le applicazioni pratiche sono numerose: dall'accessibilità per persone con disabilità visive, all'indicizzazione automatica di grandi archivi fotografici, fino all'arricchimento di sistemi di ricerca visiva. La difficoltà principale risiede nel costruire un ponte efficace tra due spazi molto diversi, quello delle rappresentazioni visive e quello del linguaggio, in modo che il modello non si limiti ad elencare oggetti presenti nell'immagine, ma produca descrizioni coerenti, contestualizzate e grammaticalmente corrette.

Negli ultimi anni, l'avvento dei transformer ha radicalmente trasformato lo stato dell'arte sia in computer vision che in NLP. Architetture come ViT (Vision Transformer) e model-

li linguistici autoregressivi come GPT-2 hanno reso possibile affrontare l'Image Captioning con componenti pre-addestrati su larga scala, riducendo la necessità di training from scratch e migliorando la capacità di generalizzazione. Un ulteriore salto qualitativo è stato introdotto da CLIP (Contrastive Language-Image Pretraining), un encoder visivo addestrato su 400 milioni di coppie immagine-testo provenienti dal web, che produce rappresentazioni visive semanticamente allineate al linguaggio.

In questo lavoro, presentiamo uno studio progressivo e comparativo sull'Image Captioning, condotto su Flickr8k e Flickr30k. Partendo da un sistema baseline (ViT-base + GPT-2), introduciamo una variabile alla volta — prima le best practice di training, poi la scala del dataset, infine l'upgrade dell'encoder — al fine di isolare e quantificare il contributo di ciascun fattore al miglioramento delle prestazioni. Il benchmark principale adottato è il BLEU-4, metrica standard nella letteratura sull'Image Captioning.

I risultati mostrano un miglioramento complessivo del +209% in BLEU-4 rispetto alla baseline (da 8.31 a 25.65), portando il sistema nel range dello stato dell'arte storico (2017-2018). L'analisi rivela che il fattore più impattante è stato l'aumento della scala del dataset (+94%), seguito dall'upgrade dell'encoder CLIP-L (+35%) e dalle best practice di training (+18%).

Il resto del paper è organizzato come segue: la Sezione 2 presenta il contesto bibliografico e lo stato dell'arte; la Sezione 3 descrive la metodologia e l'architettura del sistema; la Sezione 4 dettaglia gli esperimenti condotti; la Sezione 5 presenta e discute i risultati; la Sezione 6 conclude il lavoro.

2 Lavori Correlati

2.1 Approcci Classici: CNN e LSTM

I primi sistemi di Image Captioning di successo si basavano su un'architettura encoder-decoder in cui una rete convoluzionale (CNN) estraeva le feature visive dell'immagine, e una rete ricorrente (LSTM) le utilizzava per generare la sequenza di parole della didascalia. Il lavoro seminale di Vinyals et al.

(2015), "Show and Tell", ha stabilito questo paradigma come riferimento, ottenendo risultati significativi su dataset come MS-COCO e Flickr30k.

Un contributo fondamentale è stato successivamente introdotto da Xu et al. (2015) con "Show, Attend and Tell", che ha aggiunto un meccanismo di attention sopra le feature CNN. Invece di condizionare il decoder su un singolo vettore globale, il modello impara a focalizzarsi su regioni diverse dell'immagine a ogni passo della generazione, migliorando sia le prestazioni che l'interpretabilità del sistema. Questo approccio ha rappresentato lo stato dell'arte per diversi anni, con BLEU-4 su Flickr8k nell'ordine di 21-23.

2.2 L'Era dei Transformer

L'introduzione dei transformer (Vaswani et al., 2017) ha avuto un impatto profondo su entrambe le componenti del sistema. Sul lato visivo, Dosovitskiy et al. (2020) hanno proposto il Vision Transformer (ViT), che suddivide l'immagine in patch e le elabora tramite self-attention, ottenendo prestazioni competitive con le CNN su larga scala senza fare uso di convoluzioni. Sul lato linguistico, modelli autoregressivi come GPT-2 (Radford et al., 2019) hanno dimostrato eccellenti capacità di generazione di testo grazie al pre-addestramento su enormi corpora testuali.

L'applicazione di questi componenti all'image captioning ha portato a sistemi ibridi ViT+GPT-2, in cui le patch embedding dell'encoder visivo vengono proiettate nello spazio del decoder linguistico tramite uno strato di proiezione lineare. Questo approccio, pur nella sua semplicità architetturale, si è rivelato sorprendentemente efficace, specialmente quando i componenti sono pre-addestrati su larga scala.

2.3 Modelli Vision-Language: CLIP

Una svolta significativa è arrivata con CLIP (Contrastive Language-Image Pretraining), proposto da Radford et al. (2021) di OpenAI. CLIP è addestrato su 400 milioni di coppie immagine-testo raccolte dal web tramite un obiettivo di apprendimento contrastivo: l'encoder visivo e l'encoder testuale vengono ottimizzati congiuntamente per massimizzare la similarità coseno tra immagini e testi corrispondenti. Il risultato è un encoder visivo le cui rappresentazioni sono semanticamente allineate al linguaggio naturale, a differenza di ViT-base addestrato su ImageNet con obiettivo di classificazione.

Questo allineamento si traduce in una notevole capacità di generalizzazione cross-domain: le feature prodotte da CLIP descrivono il contenuto semantico dell'immagine in modo molto più ricco rispetto a un encoder puramente visivo, rendendole particolarmente adatte come input per un decoder linguistico. Lavori successivi come ClipCap (Mokady et al., 2021) hanno esplorato esplicitamente l'uso di CLIP come encoder per il captioning, ottenendo risultati nello stato dell'arte con architetture leggere. Il presente lavoro condivide con ClipCap l'intuizione di base — usare CLIP come encoder e un modello linguistico pre-addestrato come decoder — ma se ne distingue per diversi aspetti: non viene utilizzato un mapping network basato su transformer per la proiezione delle feature visive, bensì un semplice strato lineare; il decoder adottato è GPT-2 small nella sua versione standard senza fine-tuning del

prefisso; l'obiettivo non è proporre un nuovo sistema ottimizzato, ma condurre uno studio comparativo controllato in cui ogni componente viene introdotto e valutato separatamente.

2.4 Collocazione del Presente Lavoro

Il presente lavoro non propone una nuova architettura, ma conduce uno studio sistematico e progressivo su componenti esistenti, con l'obiettivo di isolare e quantificare il contributo di tre fattori chiave: le best practice di training, la scala del dataset, e la qualità dell'encoder visivo. A differenza della maggior parte dei lavori in letteratura, che presentano direttamente il sistema finale, questo studio adotta un approccio ablativo fin dall'inizio, documentando ogni passo della progressione. I risultati ottenuti — BLEU-4 di 25.65 su Flickr8k — si collocano nel range dello stato dell'arte del periodo 2017-2018, raggiunto con un'architettura modulare e riproducibile basata interamente su componenti open-source.

3 Metodologia

3.1 Architettura Generale

Il sistema adottato segue il paradigma encoder-decoder: un encoder visivo estrae una rappresentazione vettoriale dell'immagine, uno strato di proiezione lineare adatta tale rappresentazione allo spazio del decoder, e un decoder linguistico genera autoregressivamente la didascalia token per token. L'architettura è volutamente modulare, in modo da consentire la sostituzione dell'encoder visivo senza modificare il resto del sistema — scelta che ha permesso di isolare il contributo dell'encoder nei confronti delle altre variabili.

3.2 Encoder Visivo

Negli esperimenti delle Settimane 1 e 2 è stato utilizzato ViT-base/16 (google/vit-base-patch16-224-in21k), un Vision Transformer pre-addestrato su ImageNet-21k con obiettivo di classificazione. L'immagine viene suddivisa in patch 16×16, ogni patch viene linearizzata e proiettata in un embedding di dimensione 768. Il token [CLS] prodotto dall'ultimo layer del transformer viene utilizzato come rappresentazione globale dell'immagine, con dimensionalità 768.

Nella Settimana 3 l'encoder è stato sostituito con CLIP ViT-L/14 (openai/clip-vit-large-patch14), addestrato su 400 milioni di coppie immagine-testo con obiettivo contrastivo. Le differenze principali rispetto a ViT-base sono tre: la dimensione del modello (patch 14×14, dimensione embedding 1024 invece di 768), il tipo di pre-addestramento (contrastivo immagine-testo invece di classificazione ImageNet), e le statistiche di normalizzazione dell'input, che sono specifiche di CLIP e diverse da quelle standard di ImageNet. Quest'ultimo punto è critico: utilizzare le statistiche di normalizzazione errate degrada significativamente la qualità delle rappresentazioni prodotte dall'encoder.

3.3 Strato di Proiezione

Poiché il decoder GPT-2 opera in uno spazio di dimensione 768, è necessario uno strato di proiezione che adatti l'output

dell'encoder. Nel caso di ViT-base (768→768) la proiezione è l'identità. Nel caso di CLIP ViT-L (1024→768) viene utilizzato uno strato lineare senza attivazione, inizializzato automaticamente da HuggingFace. Questo strato è l'unico componente addestrato from scratch; tutti gli altri parametri sono pre-addestrati.

A differenza di ClipCap, che utilizza un mapping network basato su transformer per generare una sequenza di token di prefisso, il presente lavoro adotta una proiezione lineare diretta per mantenere l'architettura il più semplice possibile e concentrare l'analisi sulle variabili di interesse.

3.4 Decoder Linguistico

Il decoder adottato è GPT-2 small (117M parametri), un modello linguistico autoregressivo pre-addestrato su WebText. La generazione avviene token per token: a ogni passo, il modello riceve in input la rappresentazione visiva proiettata concatenata ai token già generati, e produce una distribuzione di probabilità sul vocabolario dal quale viene selezionato il token successivo. La generazione termina al token di fine sequenza [EOS] o al raggiungimento di una lunghezza massima prefissata. Durante l'inferenza viene utilizzata la beam search con ampiezza 4: a ogni passo vengono mantenute le quattro sequenze parziali più probabili, anziché impegnarsi sul singolo token a massima probabilità come nella greedy decoding, riducendo il rischio di scelte localmente ottime ma globalmente subottimali. Per contrastare i loop ripetitivi tipici di GPT-2 viene inoltre imposto un vincolo di non ripetizione dei 3-grammi (`no_repeat_ngram_size = 3`), con lunghezza massima della sequenza fissata a 30 token.

3.5 Dataset

Sono stati utilizzati due dataset:

Flickr8k è composto da 8.091 immagini, ciascuna annotata con 5 didascalie di riferimento scritte da annotatori umani. Lo split adottato è il classico 6.000/1.000/1.091 (train/validation/test). **Flickr8k** è stato utilizzato come benchmark di valutazione fisso per tutti gli esperimenti, consentendo il confronto diretto tra i risultati delle diverse settimane.

Flickr30k è composto da circa 31.000 immagini, anch'esse con 5 didascalie ciascuna, per un totale di circa 27.971 immagini di training, 1.906 di validation e 1.906 di test. Lo split è stato effettuato per immagine (non per didascalia) per evitare data leakage. **Flickr30k** è stato utilizzato come dataset di training nelle Settimane 2 e 3, con l'obiettivo di ridurre l'overfitting tramite un maggior volume di dati.

3.6 Setup di Training

Il training è stato condotto su una GPU NVIDIA RTX 5070 (12 GB VRAM) con PyTorch 2.11 e mixed precision bf16. A partire dalla Settimana 1, sono state introdotte le seguenti best practice, mantenute invariate in tutti gli esperimenti successivi.

Data augmentation. Durante il training, le immagini vengono sottoposte a trasformazioni casuali: flip orizzonta-

le, color jitter (variazioni casuali di luminosità, contrasto e saturazione) e random crop. L'obiettivo è aumentare artificialmente la variabilità del training set, in modo che il modello non memorizzi le immagini specifiche ma apprenda rappresentazioni più robuste e generalizzabili. Le trasformazioni vengono applicate esclusivamente al training set; il validation e il test set ricevono solo il resize e la normalizzazione standard.

Cosine annealing con warmup. Il learning rate non rimane costante durante il training, ma segue una curva: parte da un valore molto basso, cresce linearmente durante le prime epoche (warmup), raggiunge il picco, e poi decade seguendo una curva coseno fino a quasi zero. Il warmup iniziale evita aggiornamenti troppo aggressivi nelle prime iterazioni, quando i pesi non sono ancora orientati correttamente. Il decadimento coseno successivo permette al modello di convergere in modo stabile, riducendo il rischio di oscillare intorno al minimo senza raggiungerlo.

Early stopping. Il training viene interrotto anticipatamente se la BLEU-4 sul subset di validation non migliora per un numero prefissato di epoche consecutive (patience). Questo evita l'overfitting: senza early stopping, il modello continua ad abbassare la loss sul training set memorizzando i dati, mentre le prestazioni sul validation, e quindi sul test, peggiorano. Viene salvato esclusivamente il checkpoint corrispondente alla miglior BLEU-4 di validation osservata, scartando tutti gli altri.

Label smoothing. Invece di addestrare il modello a produrre una distribuzione di probabilità con tutta la massa concentrata sul token corretto (one-hot), il label smoothing distribuisce una piccola frazione della probabilità (0.1) uniformemente sugli altri token del vocabolario. Questo riduce l'overconfidence del modello: invece di essere "certo al 100%" della risposta giusta durante il training, impara a mantenere una leggera incertezza, il che migliora la generalizzazione al momento dell'inferenza.

Gradient accumulation (Settimana 3). Con l'introduzione di CLIP ViT-L, il maggior numero di parametri ha aumentato il consumo di memoria GPU, rendendo necessaria una riduzione della batch size da 32 a 4. Per non alterare le condizioni di training rispetto agli esperimenti precedenti, è stata utilizzata la gradient accumulation: i gradienti vengono accumulati su 8 step prima di aggiornare i pesi, ottenendo una effective batch size di 32 equivalente a quella degli esperimenti precedenti, senza richiedere memoria aggiuntiva.

3.7 Metrica di Valutazione

La metrica principale adottata è il BLEU-4 (Bilingual Evaluation Understudy), che misura la sovrapposizione di n-grammi (fino a 4-grammi) tra la didascalia generata e le didascalie di riferimento. Il BLEU-4 è la metrica standard nella letteratura sull'image captioning e consente il confronto diretto con i risultati riportati in letteratura. Viene calcolato a livello di corpus sull'intero test set, non come media per immagine, per una stima più robusta.

È noto che il BLEU-4 presenta alcune limitazioni: non cattura la qualità semantica delle descrizioni, penalizza le parafrasi corrette che usano vocabolario diverso dai riferimenti, e tende a sottostimare le prestazioni su descrizioni più lunghe. Tuttavia, rimane lo strumento di confronto più consolidato per questo tipo di task e dataset.

4 Setup Sperimentale

4.1 Fase 1— Baseline

Il primo esperimento ha lo scopo di stabilire un punto di partenza numerico riproducibile. Il sistema è composto da ViT-base come encoder e GPT-2 small come decoder, addestrato su Flickr8k per 8 epoche senza alcuna tecnica di regolarizzazione o di ottimizzazione del training. Il modello mostra overfitting già a partire dall'epoca 3, con la validation loss che inizia a peggiorare mentre la training loss continua a scendere. Il miglior checkpoint si trova all'epoca 2, con una validation loss di 1.947.

La valutazione sul test set di Flickr8k (1.091 immagini) produce un BLEU-4 di 8.31. Questo valore costituisce il riferimento quantitativo rispetto al quale tutti gli esperimenti successivi vengono misurati.

4.2 Settimana 1 — Best Practice di Training su Flickr8k

Il secondo esperimento introduce le best practice di training descritte nella Sezione 3.6, mantenendo invariati architettura e dataset. L'obiettivo è verificare quanto le scelte di training, indipendentemente dall'architettura, influenzino le prestazioni finali.

Le modifiche introdotte rispetto alla baseline sono: data augmentation, cosine annealing con warmup, early stopping basato su BLEU-4 di validation, label smoothing 0.1 e mixed precision bf16. Il budget di training è esteso a 25 epoche, con early stopping che interrompe il training all'epoca 5.

La valutazione sul test set di Flickr8k produce un BLEU-4 di 9.80, con un miglioramento del +18% rispetto alla baseline. Il risultato conferma che le best practice di training hanno un impatto positivo misurabile, ma limitato quando il dataset rimane piccolo: con sole 6.000 immagini di training, il modello fatica a generalizzare indipendentemente dalle tecniche di regolarizzazione adottate.

4.3 Fase 2 — Scale-up del Dataset con Flickr30k

Il terzo esperimento sostituisce Flickr8k con Flickr30k come dataset di training, mantenendo invariati architettura e setup di training. L'obiettivo è verificare l'impatto della scala dei dati sulle prestazioni, ipotizzando che il principale limite del sistema nella Settimana 1 fosse la quantità di dati disponibili piuttosto che l'architettura.

Flickr30k fornisce circa 27.971 immagini di training, quattro volte più di Flickr8k. Lo split è effettuato per immagine per evitare data leakage. Il training converge all'epoca 5 in circa 3.7 ore.

La valutazione viene condotta su due test set distinti: Flickr8k (1.091 immagini, cross-distribution) e Flickr30k (1.906

immagini, in-distribution). I risultati sono discussi nella Sezione 5. Sul test set di Flickr8k il BLEU-4 sale a 18.99, con un miglioramento del +94% rispetto alla Settimana 1. Questo risultato conferma l'ipotesi iniziale: nel regime di dataset piccolo-medio, la quantità di dati è il fattore dominante per le prestazioni.

4.4 Fase 3 — Upgrade dell'Encoder con CLIP ViT-L

Il quarto esperimento sostituisce l'encoder ViT-base con CLIP ViT-L/14, mantenendo invariati dataset (Flickr30k) e setup di training. L'obiettivo è verificare se un encoder preaddestrato su scala web — con rappresentazioni visive semanticamente allineate al linguaggio — produca un miglioramento significativo rispetto a un encoder addestrato su ImageNet con obiettivo di classificazione.

Le uniche modifiche rispetto alla Settimana 2 sono: la sostituzione dell'encoder, l'aggiornamento dello strato di proiezione da 768→768 a 1024→768, l'adozione delle statistiche di normalizzazione specifiche di CLIP, e l'utilizzo della gradient accumulation per mantenere una effective batch size di 32 nonostante i vincoli di memoria. Il training converge all'epoca 6 su 9 epoche totali in circa 7.5 ore, con overfitting visibile a partire dall'epoca 7.

La valutazione sui due test set produce i risultati discussi nella Sezione 5. Sul test set di Flickr8k il BLEU-4 sale a 25.65, con un miglioramento del +35% rispetto alla Settimana 2. Un'osservazione importante riguarda l'asimmetria del guadagno tra i due test set: su Flickr8k (cross-distribution) il miglioramento è del +35%, mentre su Flickr30k (in-distribution) è solo del +6%. Questo suggerisce che il principale vantaggio di CLIP-L risiede nella sua capacità di generalizzazione cross-domain, mentre in-distribution il bottleneck rimane la capacità del decoder GPT-2 di adattarsi al dataset specifico.

5 Risultati e Discussione

5.1 Risultati Quantitativi

La Tabella 1 riporta i risultati completi di tutti gli esperimenti condotti, valutati sul test set di Flickr8k (1.091 immagini). Per gli esperimenti delle Settimane 2 e 3, addestrati su Flickr30k, viene riportata anche la valutazione sul test set in-distribution di Flickr30k (1.906 immagini).

Esperimento	Training Dataset	BLEU-1	BLEU-2	BLEU-3	BLEU-4	Corpus
ViT-base + GPT-2	Flickr8k	65.72	32.27	16.72	8.31	23.30
ViT-base + GPT-2	Flickr8k (BP)	68.30	35.34	18.63	9.80	25.77
ViT-base + GPT-2	Flickr30k	79.57	51.31	31.76	18.99	39.61
CLIP-L + GPT-2	Flickr30k	83.09	57.01	38.54	25.65	46.52

Tabella 1. Risultati comparativi sul test set di Flickr8k.




Figura 1

Esperimento	Training Dataset	BLEU-1	BLEU-2	BLEU-3	BLEU-4	Corpus
ViT-base + GPT-2	Flickr30k	70.17	36.40	19.54	10.49	26.90
CLIP-L + GPT-2	Flickr30k	71.13	37.33	20.36	11.13	27.85

Tabella 2. Risultati comparativi sul test set di Flickr30k.




Figura 2

5.2 Analisi Quantitativa

Il miglioramento complessivo da baseline a Settimana 3 è di +209% in BLEU-4 sul test set di Flickr8k (da 8.31 a 25.65). La Tabella 3 riassume il contributo percentuale di ciascun passo della progressione.

Passo	Modifica introdotta	BLEU-4 prima	BLEU-4 dopo	Contributo
A → Settimana 1	Best practice di training	8.31	9.80	+18%
Settimana 1 → 2	Dataset 4 × più grande (Flickr30k)	9.80	18.99	+94%
Settimana 2 → 3	Encoder CLIP ViT-L/14	18.99	25.65	+35%

Tabella 3. Contributo percentuale di ogni step al miglioramento del BLEU-4.




Figura 3

Il dato più rilevante è che il contributo maggiore proviene dal cambio di dataset (+94%), non dall'architettura. Questo risultato supporta una conclusione generale ben nota in letteratura ma spesso sottovalutata nella pratica: nel regime di dataset piccolo-medio, la quantità di dati disponibili è il fattore dominante per le prestazioni, più delle scelte architetturali o delle tecniche di training.

5.3 Analisi Qualitativa

Overfitting precoce con Flickr8k. In tutti gli esperimenti condotti su Flickr8k come dataset di training (Scenario A e Settimana 1), il modello mostra overfitting già nelle prime epoche. Con sole 6.000 immagini di training, la capacità espressiva di ViT-base + GPT-2 è sufficiente a memorizzare il training set, a scapito della generalizzazione. L'introduzione delle best practice di training nella Settimana 1 attenua il fenomeno ma non lo elimina.

Generalizzazione cross-distribution di CLIP-L.

L'osservazione più interessante dell'intero studio riguarda il comportamento asimmetrico di CLIP ViT-L sui due test set. Su Flickr8k (cross-distribution rispetto al training su Flickr30k) il guadagno è del +35%, mentre su Flickr30k (in-distribution) il guadagno è solo del +6%. Questo suggerisce che il principale vantaggio di CLIP-L non risiede nella sua capacità di fitting al dataset specifico, ma nella qualità e generalità delle sue rappresentazioni visive, costruite su 400 milioni di coppie immagine-testo del web. Un encoder addestrato su ImageNet con obiettivo di classificazione produce rappresentazioni ottimizzate per distinguere categorie di oggetti, ma non necessariamente per descrivere scene in linguaggio naturale. CLIP, essendo addestrato con un obiettivo direttamente allineato al linguaggio, produce feature più ricche e semanticamente espressive, che il decoder GPT-2 riesce a sfruttare meglio soprattutto su distribuzioni di immagini diverse da quelle viste durante il training.

Stabilità della lunghezza delle didascalie. Un indicatore indiretto della qualità del sistema è la lunghezza media delle didascalie generate rispetto a quelle di riferimento. In tutti gli esperimenti, la lunghezza media generata rimane molto vicina a quella dei riferimenti (ad esempio, 11.27 vs 11.09 token nella Settimana 3 su Flickr8k), con una brevity penalty pari a 1.0. Questo indica che il modello non ricorre a strategie degeneri come “generare frasi molto corte” per massimizzare la precisione degli n-grammi.

5.4 Confronto con lo Stato dell’Arte

Per contestualizzare i risultati ottenuti, è utile confrontarli con i principali sistemi presenti in letteratura, organizzati cronologicamente per generazione tecnologica.

I sistemi della prima generazione, basati su CNN+LSTM, raggiungono su Flickr8k valori di BLEU-4 nell’ordine di 21-23. “Show, Attend and Tell” (Xu et al., 2015), che introduce il meccanismo di attention sopra le feature CNN, è il rappresentante più noto di questa famiglia e costituisce di fatto il primo riferimento storico consolidato per questo benchmark.

I sistemi della generazione successiva, basati su transformer, hanno spostato lo stato dell’arte verso valori di BLEU-4 compresi tra 25 e 30 su Flickr8k. Questi sistemi utilizzano tipicamente encoder visivi pre-addestrati su larga scala e decoder basati su attention multi-head, con architetture più complesse e costose da addestrare rispetto a quella adottata in questo lavoro.

I sistemi più recenti (2022-2024), basati su modelli vision-language di grandi dimensioni come BLIP, OFA o varianti di CLIP con decoder dedicati, raggiungono valori di BLEU-4 superiori a 35-40 su Flickr8k. Questi risultati richiedono tuttavia risorse computazionali e volumi di dati di pre-addestramento enormemente superiori a quelli disponibili in questo lavoro, e non sono quindi un riferimento diretto per il confronto.

Il risultato finale di questo lavoro (BLEU-4 = 25.65 su Flickr8k) si colloca nella fascia alta dello stato dell’arte del periodo 2017-2018, raggiunto con un’architettura modulare e semplice basata interamente su componenti open-source pre-addestrati, senza alcuna componente custom o fine-tuning specifico per il task.

È importante sottolineare che il confronto diretto con la letteratura va interpretato con cautela: le implementazioni, gli split dei dataset e le procedure di valutazione possono differire tra i lavori, introducendo variazioni nei risultati non attribuibili alle sole scelte architettureali. In particolare, alcuni lavori calcolano il BLEU come media per immagine invece che a livello di corpus, il che può produrre valori numericamente diversi anche a parità di sistema.

6 Conclusioni

In questo lavoro è stato presentato uno studio progressivo e comparativo sull’image captioning, condotto su Flickr8k e Flickr30k. Partendo da un sistema baseline composto da ViT-base e GPT-2 small con BLEU-4 di 8.31, sono stati introdotti sequenzialmente tre fattori di miglioramento —

best practice di training, scale-up del dataset, e upgrade dell’encoder visivo con CLIP ViT-L/14 — raggiungendo un BLEU-4 finale di 25.65 sul test set di Flickr8k, con un miglioramento complessivo del +209%.

Il contributo principale di questo lavoro non è architetturale, ma analitico: ogni esperimento ha introdotto una sola variabile alla volta, consentendo di attribuire con precisione il miglioramento al fattore corretto. I risultati mostrano chiaramente che, nel regime di dataset piccolo-medio, la quantità di dati disponibili è il fattore dominante (+94%), più delle scelte architettureali o delle tecniche di training. L’upgrade dell’encoder con CLIP ViT-L ha prodotto un guadagno significativo (+35%), particolarmente evidente in cross-distribution, confermando che rappresentazioni visive semanticamente allineate al linguaggio migliorano la capacità di generalizzazione del sistema al di là del dataset di training.

Limitazioni. Il sistema presenta alcune limitazioni che è opportuno esplicitare. Il decoder GPT-2 small, pur essendo efficace, è un modello relativamente piccolo che non è stato fine-tunato specificamente per il task di captioning: un decoder più grande o specializzato potrebbe migliorare ulteriormente le prestazioni. La generazione adotta la beam search; strategie di decoding stocastico come il nucleus sampling non sono state esplorate e potrebbero produrre didascalie lessicalmente più variegata, al costo però di una minore aderenza ai riferimenti. Infine, la metrica BLEU-4, pur essendo lo standard consolidato per il confronto in letteratura, non cattura pienamente la qualità semantica delle descrizioni generate.

Sviluppi futuri. Le direzioni più promettenti per estendere questo lavoro includono: l’adozione di un decoder più potente, come GPT-2 medium o large, o di modelli linguistici più recenti; la sperimentazione di strategie di decoding stocastico come il nucleus sampling; la valutazione con metriche complementari al BLEU-4, come CIDEr o METEOR, più sensibili alla qualità semantica; l’estensione del training a dataset più grandi come MS-COCO, che con oltre 80.000 immagini rappresenta il benchmark di riferimento più ampio per l’image captioning.

Riferimenti bibliografici

- [1] O. Vinyals, A. Toshev, S. Bengio, and D. Erhan, “Show and tell: A neural image caption generator,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 3156–3164, 2015.
- [2] K. Xu, J. Ba, R. Kiros, K. Cho, A. Courville, R. Salakhutdinov, R. Zemel, and Y. Bengio, “Show, attend and tell: Neural image caption generation with visual attention,” in *International Conference on Machine Learning (ICML)*, pp. 2048–2057, 2015.
- [3] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

- [4] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, ... and N. Houlsby, “An image is worth 16×16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations (ICLR)*, 2021.
- [5] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, and I. Sutskever, “Language models are unsupervised multitask learners,” *OpenAI Blog*, 2019.
- [6] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, ... and I. Sutskever, “Learning transferable visual models from natural language supervision,” in *International Conference on Machine Learning (ICML)*, pp. 8748–8763, 2021.
- [7] R. Mokady, A. Hertz, and A. H. Bermano, “Clip-Cap: CLIP prefix for image captioning,” *arXiv preprint arXiv:2111.09734*, 2021.